

Trabajo Práctico N.º 3 - Grupo 2

Clasificación de la informalidad laboral en Argentina utilizando microdatos de la EPH,
cuarto trimestre de 2024 y 2025

Taller de Programación - Universidad de Buenos Aires

17 de agosto de 2026

Repositorio GitHub:

https://github.com/achasinavas/Taller_de_Programacion_UBA

1. Introducción

La Encuesta Permanente de Hogares (EPH), elaborada por el Instituto Nacional de Estadística y Censos (INDEC), permite estudiar las características sociodemográficas y laborales de la población argentina. En este trabajo se utilizan los microdatos individuales correspondientes al cuarto trimestre de 2024 y al cuarto trimestre de 2025 con el objetivo de predecir la informalidad laboral a partir de métodos supervisados de clasificación.

El grupo 2 trabaja con la categoría *Upper-tier informal wage employees*. En términos operativos, se clasifica como informal a la persona ocupada que cumple simultáneamente tres condiciones: es asalariada, no tiene descuento jubilatorio y trabaja en establecimientos de más de cinco personas. Esta variable fue construida a partir de las variables CAT_OCUP, PP07H y PP04C.

A diferencia de los trabajos anteriores, el TP3 utiliza un enfoque predictivo. La base de 2024 se emplea como entrenamiento y la base de 2025 como testeo. Además, se estima una segunda especificación que incorpora la informalidad observada en 2024 para las mismas personas identificadas en 2025, siguiendo la idea de persistencia y transición laboral discutida por Maurizio y Monsalvo (2021).

2. Datos y estrategia de validación

La matriz de características incluyó variables creadas en los TP anteriores: edad, edad al cuadrado, años de educación, horas trabajadas por el jefe del hogar, tamaño del hogar, ingreso de la ocupación principal, tamaño del establecimiento y variables dicotómicas sociodemográficas y laborales. Para evitar redundancias, no se incorporaron simultáneamente dummies de nivel educativo y años de educación.

Tabla 1: Tamaño de las bases utilizadas

Base	Observaciones
Base EPH 2024 original	46.860
Base EPH 2025 original	43.703
Ocupados 2024	21.132
Ocupados 2025	19.698
Train 2024 usado en modelos	11.789
Test 2025 usado en modelo 1	10.849
Base 2025-MM con <i>inner join</i>	3.163

La base `ocupados_X_2025_MM` se obtuvo mediante una unión por intersección entre los individuos observados en 2024 y 2025, utilizando `CODUSU`, `NRO_HOGAR` y `COMPONENTE`. Esta base permite agregar la variable `informal_2024`, que captura si la misma persona era informal en el año anterior.

3. Balance entre entrenamiento y testeo

La Tabla 2 compara las medias de las características utilizadas en el entrenamiento de 2024 y el testeo de 2025. Esta comparación permite evaluar si las muestras presentan diferencias relevantes antes de estimar los modelos.

Tabla 2: Balance table: train 2024 vs. test 2025

Variable	Media 2024	Media 2025	Diferencia	p-value	Sig.
Edad	41,625	42,266	0,640	0,000	***
Edad ²	1.900,291	1.958,227	57,936	0,000	***
Educación	12,300	12,242	-0,058	0,227	
Horas trabajadas jefe	39,069	39,676	0,607	0,007	***
Miembros del hogar	3,318	3,287	-0,031	0,163	
P21	912.092,446	1.016.792,371	104.699,926	0,000	***
PP04C	5,686	5,498	-0,188	0,000	***
Mujer	0,438	0,447	0,010	0,142	
Casado/unido	0,573	0,572	-0,001	0,936	
Asalariado	0,688	0,666	-0,021	0,001	***
Cobertura de salud	0,744	0,735	-0,009	0,123	

Nota: *** indica significancia estadística al 1 %.

Se observan diferencias estadísticamente significativas en edad, edad al cuadrado, horas trabajadas por el jefe del hogar, ingreso de la ocupación principal, tamaño del establecimiento y condición de asalariado. En cambio, no se detectan diferencias significativas en años de educación, tamaño del hogar, sexo, estado civil ni cobertura de salud. Por lo tanto, la evaluación fuera de muestra resulta necesaria para analizar si el modelo entrenado en 2024 generaliza adecuadamente a 2025.

4. Modelos de regresión logística

Se estimaron dos modelos logit. El Modelo 1 se entrena con información de 2024 y se evalúa sobre 2025. El Modelo 2 utiliza la base 2025-MM e incorpora como predictor adicional la informalidad observada en 2024. La probabilidad estimada se define como:


$$Pr(informal_i = 1 \mid X_i) = \frac{1}{1 + e^{-(\beta_0 + X_i' \beta)}}.$$

Tabla 3: Coeficientes seleccionados de los modelos logit

Modelo	Variable	Coef.	Error est.	Odd-ratio
Modelo 1	Edad	-1,216	0,245	0,296
Modelo 1	Educación	-0,044	0,044	0,957
Modelo 1	P21	-1,382	0,093	0,251
Modelo 1	PP04C	1,410	0,067	4,097
Modelo 1	Cobertura de salud	-2,591	0,114	0,075
Modelo 2	Edad	-0,683	0,595	0,505
Modelo 2	Educación	0,033	0,105	1,034
Modelo 2	P21	-1,301	0,217	0,272
Modelo 2	PP04C	1,339	0,161	3,814
Modelo 2	Cobertura de salud	-2,747	0,274	0,064
Modelo 2	Informalidad 2024	3,001	0,218	20,098

En ambos modelos, el ingreso de la ocupación principal se asocia negativamente con la probabilidad de informalidad, mientras que el tamaño del establecimiento se asocia positivamente con la definición operacional usada para el grupo. Al incorporar la informalidad previa, los coeficientes de edad y educación pierden relevancia estadística, mientras que `informal_2024` se convierte en el predictor más importante. Su odd-ratio cercano a 20 evidencia una fuerte persistencia de la condición de informalidad.

La Figura 1 muestra la probabilidad predicha de informalidad en 2025 contra los años de educación, usando los coeficientes estimados con la base de 2024.

**Figura 1:** Probabilidad predicha de informalidad en 2025 según años de educación

La probabilidad predicha promedio es relativamente baja en todos los tramos educativos, aunque presenta cierta heterogeneidad. La relación con educación no debe interpretarse aisladamente, dado que el modelo controla simultáneamente por ingreso, edad, tamaño del establecimiento, horas trabajadas y otras características.

5. Desempeño predictivo y discusión de política pública

Para evaluar los modelos se utilizaron matrices de confusión con umbral $p > 0,5$, curvas ROC y métricas de clasificación. La Figura 2 presenta las matrices de confusión de ambos modelos.




Figura 2: Matrices de confusión de los modelos logit

Tabla 4: Métricas de desempeño de los modelos

Modelo	Accuracy	Precision	Recall	F1	AUC
Modelo 1	0,9331	0,9070	0,2812	0,4292	0,8748
Modelo 2	0,9459	0,7388	0,4213	0,5366	0,9153




Figura 3: Curvas ROC de los modelos logit

El Modelo 1 alcanza alta exactitud global, pero detecta una proporción limitada de trabajadores informales. El Modelo 2 mejora el recall, el F1-score y el AUC, aunque reduce la precisión. Si el objetivo de política pública es identificar trabajadores precarizados para focalizar recursos de formalización laboral, el Modelo 2 resulta más adecuado, porque disminuye los falsos negativos y detecta una mayor proporción de informales. En este contexto, incluso podría considerarse un umbral menor a 0,5 si se busca priorizar cobertura por sobre precisión.

6. Conclusiones

El análisis muestra que la incorporación del estatus de informalidad previo mejora la capacidad predictiva del modelo. Esto es consistente con la persistencia de la informalidad laboral: quienes fueron informales en 2024 tienen una probabilidad considerablemente mayor de ser clasificados como informales en 2025. En términos de evaluación fuera de muestra, el Modelo 2 presenta mejor desempeño general y es más útil para fines de política pública orientados a detectar trabajadores informales.

A. Tabla completa de modelos logit

Tabla 5: Modelos logit completos: coeficientes, errores estándar y odd-ratios

Modelo	Variable	Coef.	Error est.	Odd-ratio	Signif.
Modelo 1	Edad	-1,2162	0,2447	0,2964	***
Modelo 1	Edad ²	1,1314	0,2583	3,1000	***
Modelo 1	Educación	-0,0441	0,0443	0,9569	
Modelo 1	Horas trabajadas jefe	-0,0333	0,0388	0,9672	
Modelo 1	Miembros del hogar	-0,0771	0,0369	0,9258	**
Modelo 1	P21	-1,3817	0,0934	0,2512	***
Modelo 1	PP04C	1,4101	0,0668	4,0966	***
Modelo 1	Mujer	0,1704	0,0793	1,1858	**
Modelo 1	Casado/unido	0,0483	0,0821	1,0495	
Modelo 1	Asalariado	25,9880	13.862,4742	—	
Modelo 1	Cobertura de salud	-2,5906	0,1139	0,0750	***
Modelo 2	Edad	-0,6825	0,5948	0,5054	
Modelo 2	Edad ²	0,7143	0,6217	2,0429	
Modelo 2	Educación	0,0331	0,1052	1,0337	
Modelo 2	Horas trabajadas jefe	0,1066	0,0857	1,1124	
Modelo 2	Miembros del hogar	-0,1141	0,0882	0,8921	
Modelo 2	P21	-1,3010	0,2169	0,2723	***
Modelo 2	PP04C	1,3387	0,1614	3,8139	***
Modelo 2	Mujer	-0,0959	0,1920	0,9086	
Modelo 2	Casado/unido	0,2011	0,2021	1,2227	
Modelo 2	Asalariado	24,8721	15.964,4940	—	
Modelo 2	Cobertura de salud	-2,7474	0,2742	0,0641	***
Modelo 2	Informalidad 2024	3,0006	0,2182	20,0979	***

Nota: *** p<0,01; ** p<0,05. Los odd-ratios de la variable asalariado no se reportan por su magnitud extrema.

B. Probabilidad predicha por tramo educativo

	educ_bin	educ_promedio	prob_promedio	informal_observada	n
0	(-0.019, 1.583]	0.2308	0.0920	0.0769	13
1	(1.583, 3.167]	2.5000	0.0621	0.0000	16
2	(3.167, 4.75]	4.0000	0.0653	0.0909	11
3	(4.75, 6.333]	5.9561	0.0846	0.1066	319
4	(6.333, 7.917]	7.0000	0.0600	0.0545	55
5	(7.917, 9.5]	8.5469	0.0873	0.1016	256
6	(9.5, 11.083]	10.4020	0.1305	0.1275	102
7	(11.083, 12.667]	12.0000	0.0802	0.0682	1055
8	(12.667, 14.25]	13.6821	0.0805	0.1231	195
9	(14.25, 15.833]	15.0000	0.0654	0.0489	532
10	(15.833, 17.417]	16.8777	0.0519	0.0576	556
11	(17.417, 19.0]	18.9623	0.0334	0.0566	53

Figura 4: Tabla generada en el notebook: probabilidad predicha por tramo educativo

C. Uso de herramientas de IA

Durante el desarrollo del trabajo se utilizó ChatGPT como apoyo principal para organizar y corregir el código en Python, interpretar errores, estructurar el notebook, Las decisiones metodológicas finales, la validación de resultados y la interpretación económica fueron realizadas por el grupo.

Prompts principales

1. “En el contexto del tp3, verifica y analiza si la variable está creada correctamente”
2. “Hay un error en este código: `SyntaxError: unterminated string literal`, qué hacer para corregirlo?”
3. “Evalúa estas salidas ”
4. “Estrictamente necesito que cambies el formato de este informe con el informe de referencia que te entrego. ”

Modelo utilizado: ChatGPT GPT-5.5.

Tiempo total aproximado: 20 horas.

D. Referencias

Maurizio, R. y Monsalvo, A. P. (2021). *Informality, labour transitions, and the livelihoods of workers in Latin America*. WIDER Working Paper No. 2021/19. UNU-WIDER.